

UNIVERSIDAD **AUTÓNOMA DE OCCIDENTE**

Frameworks y herramientas para Big Data

Oscar Andrés Jiménez V.

www.uao.edu.co



Almacenamiento y arquitecturas de datos

- Parcial
- Proyecto



Parcial corte 1

- Cámaras encendidas durante todo el parcial.
- 25 Preguntas.
- Tiempo del parcial 35 Minutos.
- Ventana de disponibilidad del parcial 40 min.

Proyecto corte 1


Aplicar lo aprendido en este primer corte en el uso de herramientas para el despliegue de los primeros componentes que conformarán nuestro data stack.

- Data lake (Minio)
- Data warehouse (Clickhouse)
- File format (Parquet)
- Table format (Apache Iceberg)
- Catalog (Nessie)
- Ingesta de datos (dlt)

Proyecto corte 1

- http-to-bucket (Minio)
 - Guardar el archivo parquet desde la fuente en bucket de Minio.
- Parquet-to-Iceberg
 - Leer el archivo parquet que está en el bucket de Minio y guardarlo en otro bucket como formato de tabla Iceberg.
 - Al guardar en iceberg usar el catálogo de Nessie.
- Minio-to-Azure
 - Mover el archivo parquet de Iceberg desde Minio a Azure (cada grupo tiene su propia carpeta).
- Minio-to-Clickhouse
 - Insertar el archivo parquet de Iceberg desde Minio a Clickhouse.

Proyecto corte 1



Proyecto corte 1 - Accesos

- `parquet_url =`
`"https://d37ci6vzurychx.cloudfront.net/trip-data/yellow\_tripdata\_2025-01.parquet"`
- Configuración para destino ADLS

```
[s3_to_adls.destination.filesystem]
```

```
bucket_url = "abfss://clase-4-dlt@fhbd.dfs.core.windows.net/GRUPO_X"
```

```
[s3_to_adls.destination.filesystem.credentials]
```

```
azure_storage_account_name = "fhbd"
```

```
azure_storage_account_key =
```

```
"TrAwWJNvQURXIUHae6hJ929NvyNtcMCoID3MVgN3pieLNQR6c8Rk0gpLCEm9I+  
qnEiKimAwlpKFj+AStnjOKew=="
```

Proyecto corte 1 - Consideraciones

1. La ingesta y carga de datos entre fuentes y destinos debe hacerse con dlt.
2. Recuerden usar pyarrow para leer los archivos parquet.
3. El contenedor de docker debe estar funcionando con:
 - Jupyter Notebook
 - Minio
 - Nessie
 - Clickhouse
4. Ningún notebook debe tener las librerías “Quemadas”. Todas deben quedar listas desde el requirements.txt
5. Se ejecutará en clase el desarrollo entregado.

Proyecto corte 1 - Ayudas

- <https://dlthub.com/docs/pipelines/filesystem-local/load-data-with-python-from-filesystem-local-to-clickhouse>
- <https://dlthub.com/docs/dlt-ecosystem/destinations/clickhouse>
- <https://www.dremio.com/blog/intro-to-pyiceberg/>
- Scripts de las clases.
- SHOW TABLES FROM default;

Proyecto corte 1 - Entregables

- 4 Scripts de ingesta y cargue de datos
- 1 Archivo docker-compose.yml
- 1 Archivo con los secrets de dlt
- 1 Documento con los pantallazos de:
 - Los servicios corriendo en docker
 - Los dos buckets en Minio con sus respectivos archivos parquet cargados.
 - Catálogo de Nessie con el namespace creado.
 - Consulta con cantidad de registros en tabla de Clickhouse (3475226).
 - Consulta con las tablas de metadatos en Clickhouse.
 - Consulta de Archivo cargado en Azure (Investigar).

¡Gracias por su atención!

